🚀 Evaluación Parcial N°1: Proyecto Integrado de Ciencia de Datos

Asignatura: Programación para la Ciencia de Datos (SCY1101)

Ponderación Total: 30% (10% Encargo Grupal / 20% Presentación Individual)

📢 Lanzamiento del Desafío

Estimados estudiantes: Damos inicio a la **Evaluación Parcial N°1**, el desafío más importante de esta primera etapa. En equipos de **2 o 3 integrantes**, deberán actuar como Científicos de Datos para resolver un caso real de transformación y preparación de datos.

Su misión es transformar un archivo "crudo" en un reporte limpio, profesional y reproducible que pueda ser compartido con otros científicos a través de **GitHub**.

📂 Fase 1: Selección de Dataset y Equipos

Cada equipo debe buscar y seleccionar un Dataset para trabajar. El archivo debe ser lo suficientemente rico para aplicar limpieza y transformaciones avanzadas.

¿Dónde buscar y qué temas elegir? Fuentes recomendadas: Kaggle, Google Dataset Search o portales de Datos Abiertos.

- **Salud:** Indicadores de enfermedades o registros hospitalarios.
- **Transporte/Logística:** Flujo vehicular o retrasos en vuelos.
- **Clima:** Series históricas de temperatura y eventos extremos.
- **Deportes:** Estadísticas de rendimiento o datos biométricos.
- **Economía/Retail:** Ventas históricas o comportamiento de clientes.

⚠️ **Requisitos del Dataset:** Para alcanzar la nota máxima, el archivo **NO debe estar limpio**. Debe permitirles:

1. **Limpiar:** Manejar nulos (NaN), duplicados o valores atípicos (outliers).
2. **Transformar:** Escalar variables numéricas y codificar categóricas (One-Hot/Label Encoding).
3. **Crear:** Generar nuevas columnas útiles (**Feature Engineering**).

📅 Calendario de Trabajo y Hitos

Semana Actual: Desarrollo en Laboratorio

- **Sesión 1: Hoy Martes (Bloques 1 y 2)**
  - **Hito:** Conformación de equipos e investigación del tema.
  - **Meta:** Al finalizar la clase, el grupo debe tener su dataset elegido y el repositorio en GitHub creado.
- **Sesión 2: Miércoles (Bloques 1, 2 y 3)**
  - **Hito:** Trabajo intenso de programación.
  - **Meta:** Aplicación de **Pipelines**, limpieza y generación de reportes.
  - **ENTREGA:** Se deben enviar los links del repositorio y el informe/notebook por la plataforma.

Semana Próxima: Presentaciones

- **Sesión 3 y 4:** Exposición de resultados.
- **Formato:** El profesor sorteará los grupos. Cada equipo tendrá **10 minutos** para presentar sus *insights* y justificar técnicamente sus transformaciones.

📥 Requisitos Obligatorios de Entrega (GitHub)

El repositorio debe estar organizado de la siguiente manera para ser evaluado:

1. **Carpeta /data:** Conteniendo el archivo crudo (raw) y el procesado (processed).
2. **Notebook (.ipynb):** Con todas las fases (Limpieza, Transformación con Pipeline y Visualización) y celdas de **Markdown** explicando cada paso.
3. **README.md:** Debe incluir:
   - Nombre de los integrantes.
   - Origen y descripción de los datos.
   - **Justificación del entorno:** Explicar por qué prefirieron usar Google Colab o Jupyter Local y su facilidad de integración con GitHub.

🎓 **Tips para el Éxito (Basado en Pauta)**

- **Justificación Técnica:** No basta con aplicar código; deben explicar por qué esa técnica (ej. *StandardScaler*) es necesaria para sus datos.
- **Versionado Real:** Se revisará el historial de GitHub. Todos los integrantes deben tener aportes (**commits**) registrados.
- **Reproducibilidad:** El código debe correr "a la primera" al ser descargado desde el repositorio.

🚩 **¡A trabajar! Estaré disponible durante toda la sesión para validar sus temas y apoyar la configuración de sus repositorios.**